

汤济玮

[[个人主页](#)] ■ 硕士 ■ 男 ■ 共青团员 ■ 电话/微信: 13632108098 ■ Email: tangjw24@mails.tsinghua.edu.cn

教育背景

工学硕士 ■ 清华大学 (推免) (985) 计算机技术 2024.09 – 2027.06

■ 研究方向: 自然语言处理, 大语言模型 ■ 硕士期间荣誉: 清华大学三好学生, 清华大学院级奖学金

工学学士 ■ 暨南大学 (211) 计算机科学与技术 2020.09 – 2024.06 ■ 排名: 1 / 99

■ 本科期间荣誉: 国家奖学金, 优秀毕业生, 优秀毕业论文, 优秀学生二次, 优秀学生一等奖学金二次



主要学术成果 [[学术主页](#)] (*表示同等贡献)

- GMSA: Enhancing Context Compression via Group Merging and Layer Semantic Alignment**
Tang et al., *ACL*, 2026 (第一作者, **CCF-A, Oral**, 最佳论文提名, **Top 0.8 %**, 改进版落地于**淘宝首猜**) [[文章链接](#)]
- COMI: Coarsed-to-fined Context Compression via Marginal Information Gain**
Tang et al., *ICLR*, 2026. (第一作者, **CCF-A**, 得分 8 6 6 6, **247000+** 浏览) [[文章链接](#)][[推特](#)][[量子位](#)]
- Read As Human: Compressing Context via Parallelizable Close Reading and Skimming**
Tang et al., *ACL*, 2026. (第一作者, **CCF-A**, **217000+** 浏览) [[文章链接](#)][[推特](#)][[量子位](#)]
- Perception Compressor: A Training-Free Prompt Compression Framework in Long Context Scenarios**
Tang et al., *Findings of NAACL*, 2025. (第一作者, **CCF-B**) [[文章链接](#)]
- When Hard Negatives Hurt: Bridging the Generative-Discriminative Gap in Hard Negative Synthesis**
Zhang*, Tang* et al., *KDD*, 2026. (共同一作, **CCF-A**)
- CoS: Towards Optimal Event Scheduling via Chain-of-Scheduling**
Zhao, Tang et al., *AAAI*, 2026 (第二作者, **CCF-A**) [[文章链接](#)]
- Beyond Position Bias: Shifting Context Compression from Position-Driven to Semantic-Driven**
Tang et al., *NeurIPS*, 2026. (Under Review, 第一作者, **CCF-A**) [[文章链接](#)]
- CoS-R1: Enhancing Chain-of-Scheduling Reasoning Capability via Reinforcement Learning**
Tang et al., *TMC*, 2026. (Under Review, 第一作者, **CCF-A**)
- Data Distribution Matters: A Data-Centric Perspective on Context Compression for Large Language Model**
Lv*, Tang* et al., *EMNLP*, 2026. (Under Review, 共同一作, **Tsinghua-A**) [[文章链接](#)]

其中, COMI、RAM、Perception Compressor 和 GMSA 被 [GitHub](#) 上 **400+** Stars 的项目收录。 [[项目链接](#)]

实习经历

■ 2025.7 – 2026.4 阿里巴巴集团 未来生活实验室-大模型训练部门 研究型实习生

· 项目一: 通过边际信息收益从粗到细文本压缩研究 (第一作者, *ICLR* 2026)

[研究问题] 现有任务相关文本压缩方法保留内容冗余, 易误导模型。

[主要工作] 引入“边际信息收益”指标量化文本单元价值, 设计从粗到细两阶段压缩流程, 实现冗余与关键信息的动态平衡。最终实现, 32×压缩率下, Qwen2-7B 在 NaturalQuestions 数据集 EM 达 49.15, 较次优基线提升 25 个百分点; 16×压缩下 Qwen3-4B F1 超原始提示 2 倍, 推理加速 2 倍以上。

· 项目二: 通过并行化的精读、略读策略压缩文本 (第一作者, *ACL* 2026)

[研究问题] 现有方法效率低、易丢失关键信息或丧失可解释性。

[主要工作] 提出 RAM 框架, 借鉴人类阅读模式, 设计并行化精读 (保原始文本) 与略读 (结构化压缩) 机制, 引入对比学习优化边界区分。最终实现, 4×压缩率下 Qwen3-4B 在 NaturalQuestions 上 EM 66.59、F1 59.97; 32×压缩时 NarrativeQA 数据集端到端延迟仅 0.20 秒, 大幅优于基线。

· 项目三: 数据分布对大语言模型上下文压缩的影响研究 (共同一作, under review at *EMNLP* 2026)

[研究问题] 现有研究忽视数据分布对压缩质量的影响, 导致性能波动、跨域可靠性不足。

[主要工作] 以数据为中心, 构建可控自编码器框架, 预训练可控分布的编码器-解码器, 量化输入复杂度并分析分布影响。最终发现, 输入熵与压缩质量负相关 (encoder 视角); 编码器-解码器分布对齐时 F1 达 81.57%, 分布差距最大时降至 69.44%, 解码器分布起主导作用。

■ 2026.4 – 至今 蚂蚁集团 语言基座-Ling 后训练团队 研究型实习生

[主要工作] 优化基座的复杂指令遵循能力, 该能力将上线 Ling-3.0-1T。优化基座的金融工具调用能力。

个人技能

■ 技能: Claude Code, Python, Pytorch, Latex, Linux, SSH; 语言: 普通话, 英语 (CET-6)